

Міністерство Освіти та Науки України
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ імені ІВАНА ФРАНКА
Факультет прикладної математики та інформатики
Кафедра дискретного аналізу та інтелектуальних систем

**ЗВІТ ПРО ВИКОНАННЯ
ІНДИВІДУАЛЬНОГО ЗАВДАННЯ №2**

**З дисципліни
Теорія Імовірності та Математична Статистика**

Виконав студент
Групи ПМІ-24
Кутко Остап

Постановка задачі: Відповідно до номеру в журналі, обрати файл з вхідними даними (вибіркою). Зчитати дані з текстового файлу, опрацювати статистичний матеріал, представивши дані таблично та графічно, на основі графічного представлення сформулювати гіпотезу про закон розподілу досліджуваної ознаки генеральної сукупності; передбачити можливість користувачу задати параметри розподілу вручну або оцінити на основі даних вибірки; для заданого користувачем рівня значущості перевірити сформульовану гіпотезу за критерієм χ^2 .

Короткі теоретичні відомості

Ряд незалежних спостережень над випадковою змінною називають **вибіркою з генеральної сукупності**.

Всяке твердження про генеральну сукупність на основі вибірки називаємо **гіпотезою**.

Виділяють два основні типи гіпотез: **про закон розподілу випадкової величини і про значення параметрів розподілу випадкової величини**.

Міркування, на основі яких приходимо до висновків про гіпотезу називаємо **статистичним доведенням**.

Критерій гіпотези – випадкова величина K , за допомогою якої проводять перевірку гіпотези.

При статистичному доведенні можливо допустити одну з двох похибок: або відкинути істинну гіпотезу (похибка 1-го типу), або прийняти хибну гіпотезу (похибка 2-го типу). Умовно допустити похибку 1-го, тобто ймовірність відкинути істинну похибку називаємо **рівнем значущості даного критерія** і позначаємо через α .

Інформацію про випадкову величину, яка міститься у гіпотезі, називають **гіпотетичною або теоретичною**, а інформацію про неї, яку отримують на підставі вибірки, називають **статистичною або емпіричною**.

Основна (нульова) гіпотеза H_0 – гіпотеза, сформульована при статистичному доведенні.

Альтернативна (конкуруюча) гіпотеза H_1 – гіпотеза, яка повністю або частково логічно заперечує нульову гіпотезу.

Емпіричне значення критерію гіпотези – значення випадкової величини K , яке обчислюється на підставі певної вибірки.

Критична область – сукупність значень критерію K , для яких нульову гіпотезу H_0 відхиляють.

Область прийняття гіпотези - сукупність значень критерію K , для яких нульову гіпотезу H_0 приймають.

Критична точка $k_{кр}$ – точка, яка відділяє критичну область і область прийняття гіпотези.

Розділяють 3 види критичних областей:

- Правостороння критична область, $K > k_{кр}$;
- Лівостороння критична область, $K < k_{кр}$;
- Двостороння критична область, $|K| > k_{кр}$;

Потужність критерію – ймовірність того, що нульова гіпотеза буде відхилена, якщо правильна конкуруюча гіпотеза, тобто ймовірність не допустити помилку другого роду за вибраного критерію.

Для перевірки гіпотез про закон розподілу часто застосовують критерій χ^2 („хі-квадрат”, по-іншому Пірсона), який ґрунтується на визначенні відхилення емпіричних характеристик від гіпотетичних характеристик.

$$\chi^2(r, n, F) = \sum_{i=1}^r \frac{(n_i - np_i)^2}{np_i} = \sum_{i=1}^r \frac{n_i^2}{np_i} - n, \quad r - \text{кількість інтервалів}$$

Для $n \rightarrow \infty$ статистика χ^2 має розподіл, який задається густиною:

$$p_r(x) = \begin{cases} 0, & x < 0 \\ \frac{1}{\Gamma((r-1)/2)2^{(r-1)/2}} x^{((r-1)/2)-1} e^{-x/2}, & x > 0 \end{cases}$$

Розподіл з густиною $p_r(x)$ називають розподілом χ^2 з r ступенями свободи.

1. Біномний закон розподілу

Випадкова величина ξ може набувати цілих значень $0, 1, \dots, N$ з імовірностями $p_i = P(\xi=i) = C_N^i p^i (1-p)^{N-i}$, де p - параметр розподілу ($0 < p < 1$), який, якщо він невідомий, можна оцінити на підставі даних вибірки $\bar{p} = \bar{x}/N$.

2. Закон розподілу Пуассона

Випадкова величина ξ може набувати цілих значень $0, 1, \dots, m$ з імовірностями $p_i = P(\xi=i) = e^{-\lambda} \frac{\lambda^i}{i!}$, де $\lambda > 0$ - параметр розподілу, який, якщо він невідомий, можна оцінити на підставі даних вибірки $p = \bar{x}$.

3. Рівномірний закон розподілу

Функція розподілу набуває вигляду

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b. \end{cases}$$

Тут a та b – параметри розподілу, можуть бути оцінені на підставі даних вибірки $a = \bar{x} - \sqrt{3}\sigma$, $b = \bar{x} + \sqrt{3}\sigma$.

4. Показниковий закон розподілу

Функція розподілу

$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

$\lambda > 0$ – параметр розподілу, його точкова оцінка на підставі вибірки $\lambda = 1/\bar{x}$.

5. Нормальний закон розподілу

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(t-a)^2}{2\sigma^2}} dt.$$

Параметр розподілу: $\alpha = \bar{x}$.

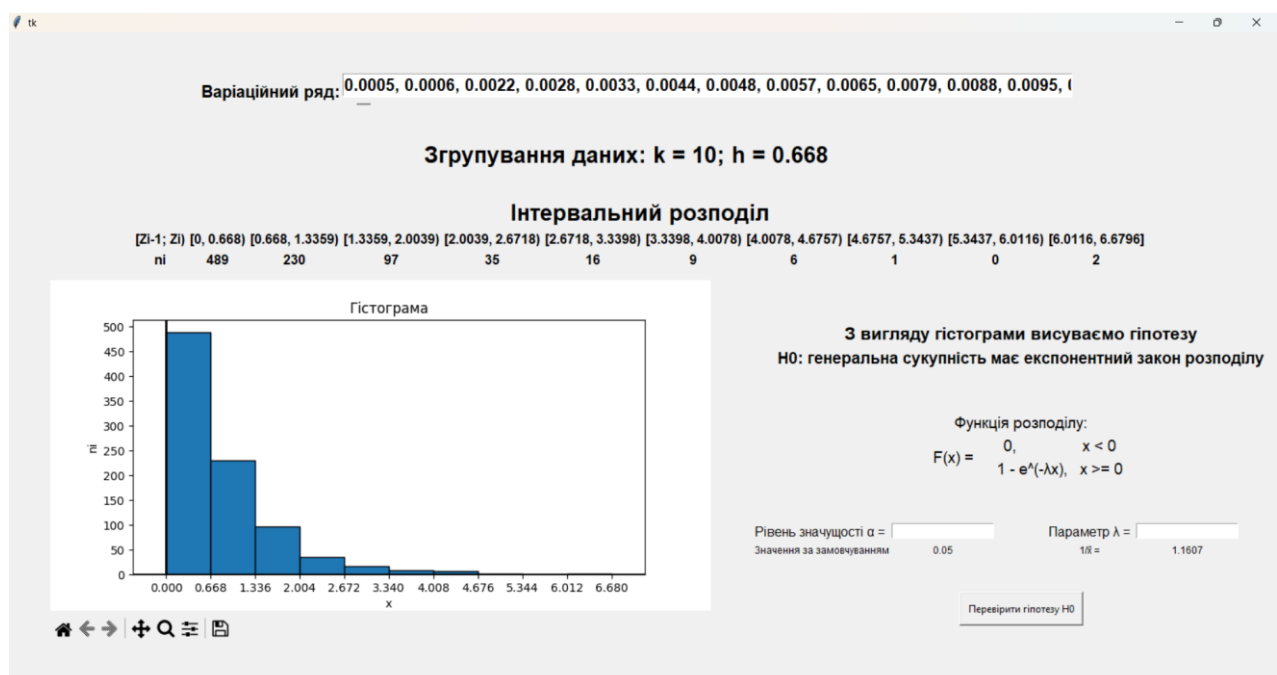
Програмна реалізація:

Програма, відповідно до варіанту, зчитує вибірку з файлу “sample6.txt”, утворює варіаційний ряд та ділить його на інтервали. Після цього за даним інтервальним розподілом будує гістограму частот. З вигляду цієї гістограми, я зробив припущення, що генеральна сукупність підпорядковується експонентному закону розподілу. У вікні програми є два поля для вводу рівня значущості та параметру λ . Якщо залишити ці поля пустими, то за замовчуванням рівень значущості буде 0.05, а $\lambda = 1/\bar{x}$, \bar{x} - середнє вибірки.

Після натискання на кнопку “Перевірити гіпотезу H_0 ” відкривається нове вікно, в якому зображено повну інтервальну таблицю (вже з рядками p_i (теоретичними імовірностями) та p_{ri}), таблицю з об’єднаними стовпцями (за умовою $n_i \geq 5$ та $p_{ri} \geq 5$), та значеннями χ^2 квадрат емпіричне та критичне. Відповідно до цих значень і сформовано результат: гіпотезу H_0 приймаємо або відхиляємо.

Програму реалізував на мові python, серед використаних структур списки та словники, використані бібліотеки: tkinter (інтерфейс), pandas (таблиці), matplotlib (гістограма), math (e та log10) та scipy (значення χ^2 квадрат критичного).

Отримані результати:



[Zi-1; Zi]	[0, 0.668)	[0.668, 1.3359)	[1.3359, 2.0039)	[2.0039, 2.6718)	[2.6718, 3.3398)	[3.3398, 4.0078)	[4.0078, 4.6757)	[4.6757, 5.3437)	[5.3437, 6.0116)	[6.0116, 6.6796]
ni	489	230	97	35	16	9	6	1	0	2
pi	0.5394	0.2484	0.1144	0.0527	0.0243	0.0112	0.0051	0.0024	0.0011	0.0009
npi	477.4118	219.851	101.2745	46.6375	21.4836	9.8943	4.5564	2.0989	0.9666	0.8254

[Zi-1; Zi]	[0, 0.668)	[0.668, 1.3359)	[1.3359, 2.0039)	[2.0039, 2.6718)	[2.6718, 3.3398)	[3.3398, 4.0078)	[4.0078, 6.6796]
ni	489	230	97	35	16	9	9
pi	0.5394	0.2484	0.1144	0.0527	0.0243	0.0112	0.0095
npi	477.4118	219.851	101.2745	46.6375	21.4836	9.8943	8.4472

$\chi^2_{\text{емп}} = 5.3508$

$\chi^2_{\text{кр}} | \alpha = 0.05; df = 5 | = 11.0705$

Гіпотезу H0 приймаємо

(тут взято значення α та λ за замовчуванням)

Висновок: Я написав програму, яка отримує вибірку з текстового файлу, групує її елементи в інтервальний розподіл та будує його гістограму частот. Пізніше перевіряє чи підпорядковується дана випадкова величина експонентному закону розподілу і виводить результат цієї перевірки.